SAMSUNG

MediBot AI — Trợ lý Y tế Đa Phương Thức

Báo cáo Toàn diện: Kiến trúc, Hiệu năng, Hạn chế và Lộ trình Phát triển

Samsung Innovation Campus — AI Capstone Project

Nhóm SIC-UTT · Nguyễn Bá Duy (TN) · Trương Tuấn Vũ · Nguyễn Trần Hiệp · Đặng Thị Thúy Linh

Phiên bản hệ thống: v3.0.0 | Ngày kiểm tra: 07/09/2026 | Môi trường: Local Development

Together for Tomorrow!

Enabling People

Education for Future Generations

Nội Dung Trình Bày

1. **Tổng quan Kiến trúc Hệ thống**
   - Hybrid Monolith: FastAPI + AI Engine
   - Luồng dữ liệu thực tế 8 bước
2. **Scorecard Tổng hợp 9 Module**
   - Điểm mạnh và khoảng cách
3. **Module A: AI Engine NLP**
   - XGBoost, TF-IDF, Hybrid Predictor
4. **Module B: NER Medical**
   - Fallback Rule-based (PhoBERT thiếu weights)
5. **Module C: STT + OCR**
   - Faster-Whisper fallback, EasyOCR
6. **Module D: RAG + LLM**
   - TF-IDF Cosine, Gemini 1.5 Flash
7. **Module E: Backend API**
   - FastAPI async, SSE Streaming, JWT
8. **Module F: Database & Persistence**
   - Điểm yếu nguy cấp: In-Memory
9. **Kết quả Hiệu năng Định lượng**
   - Bảng F1, latency, coverage
10. **Technical Debt & Lộ trình**
    - 3 Phase Production Roadmap

1. Kiến Trúc Hệ Thống Thực Tế

Loại kiến trúc hiện tại

- **Hybrid Monolith**: FastAPI Backend và AI Engine chạy cùng process — không phải microservice thực sự.
- Frontend Next.js 14 (port 3000) ↔ FastAPI (port 8000) qua HTTP REST + SSE + WebSocket.
- Backend → AI Engine: **Direct function call** (không qua mạng), nhanh nhưng không scale-out được.

Tầng Infrastructure (CHƯA KẾT NỐI)

- MongoDB Motor installed nhưng server không chạy ⇒ **In-Memory fallback**.
- Redis: config có nhưng **chưa implement** trong code.
- Qdrant: Docker-compose có, config có nhưng **chưa dùng** — RAG đang dùng TF-IDF Cosine.

Lớp	Công nghệ	Trạng thái
Frontend	Next.js 14 + Tailwind	OK
Backend	FastAPI + Uvicorn	OK
AI Engine	Python (direct call)	OK
Chat Service	628 dòng logic	OK
MongoDB	Motor Async	In-Mem
Redis Cache	aioredis	Thiếu
Qdrant VectorDB	gRPC/REST	Thiếu
File Storage	MinIO config	!

Luồng dữ liệu thực tế (8 bước)

- **[1]** Intent Guard → **[2]** AI Pipeline → **[3]** NER
- **[4]** Hybrid Predict → **[5]** RAG → **[6]** Gemini LLM
- **[7]** Clarification → **[8]** SSE Stream → Frontend

2. Scorecard Tổng hợp 9 Module

Module	Mô tả chính	Mức hoàn thiện	Trạng thái
A. AI Engine / NLP	XGBoost 32+ ICD-10, NLP TF-IDF, Hybrid Predictor, Fusion Layer, Clarification Engine	83%	OK
B. NER Medical	MedicalNER (Rule-based fallback), EntityNormalizer, RedFlagDetector, Negation	67%	!
C. STT + OCR	Whisper (simulated), Audio Preprocessor, EasyOCR, PDFParser, Lab Sanity	68%	!
D. RAG Knowledge	JSON Vector Store (TF-IDF), 41 bệnh Kaggle, QA Corpus, Qdrant config (chưa dùng)	70%	!
E. Gemini LLM	gemini-1.5-flash, System Prompt, Clinical Reasoning Fallback, Multi-turn context	78%	OK
F. Backend API	FastAPI Chat/Admin/Auth/Medical/Upload/WebSocket, Chat Service 628 dòng	73%	!
G. Database	MongoDB In-Memory fallback, Redis thiếu, Qdrant thiếu, session mất khi restart	22%	CRIT
H. Training	Training Service, Admin UI, Train Script, Dataset Builder 47KB, Model Registry	75%	OK
I. Frontend UI	Chat streaming, Admin Panel, Medical Records, Auth, Emergency Panel, TTS	78%	OK
TỔNG ĐIỂM HỆ THỐNG (MVP Chức năng cao)		68%	MVP

Các mô hình AI đang hoạt động

File	Kích thước	Trạng thái
nlp_symptom_classifier.pkl	10.5 MB	OK
nlp_tfidf_vectorizer.pkl	519 KB	OK
tabular_xgboost.json	1.54 MB	OK
label_encoder.pkl	32+ lớp ICD	OK
disease_classes_index.json	211 lớp	OK

Luồng dự đoán Hybrid Late Fusion

- Nhánh NLP: TF-IDF vectorize → LinearSVC / NLP Classifier, cho ra $P_{\text{text}}(c)$.
- Nhánh Tabular: lab features (9 CBC) → XGBoost, cho ra $P_{\text{tabular}}(c)$.
- $P_{\text{final}} = \alpha \cdot P_{\text{tabular}} + (1-\alpha) \cdot P_{\text{text}}$ với $\alpha = 0.65$ khi có lab, $\alpha = 0$ khi chỉ có text.

Clarification Engine (Shannon Entropy)

- Kích hoạt khi $P_{\max} < 0.70$: tính $H = -\sum_c P(c) \log_2 P(c)$.
- Sinh câu hỏi tối ưu hóa Information Gain trên top-3 chẩn đoán phân biệt.
- ICD-10 Q&A bank: đạt mức hoàn thiện **88%**.

Vấn đề phát hiện

- **sentence-transformers CHƯA CÀI**: Semantic fallback dùng TF-IDF thay BGE-M3 ⇒ chất lượng kém hơn.
- Chỉ **32–41 lớp ICD-10** đang active ⇒ chưa phủ hết ICD-10 Việt Nam (1.500+ mã).
- Fusion Layer đơn giản: cần nâng cấp lên **Weighted Ensemble** có học.

4. Module B+C: NER Medical & Multimodal Input

Module B: NER Medical (67%)

Sub-module	%	Trạng thái
MedicalNER (medical_ner.py)	65%	Fallback
EntityNormalizer	80%	OK
RedFlagDetector	85%	OK
Negation Detection	82%	OK
Lexicon (symptom_synonyms)	78%	OK

CRITICAL: `models_weights/phobert_ner/` **không tồn tại** ⇒ toàn bộ NER đang chạy bằng regex/dictionary rule-based.

- Ảnh hưởng lớn đến độ chính xác với triệu chứng phức tạp, mô tả dân gian.
- RedFlagDetector hoạt động tốt với pattern FAST (stroke), MI, dengue shock.

Module C: STT + OCR (68%)

Sub-module	%	Trạng thái
Whisper STT	50%	Simulated
Audio Preprocessor	80%	OK
Image OCR (EasyOCR)	70%	!
PDF Parser	75%	OK
Lab Sanity Checker	82%	OK

CRITICAL: `faster-whisper` **CHƯA CÀI** ⇒ STT trả về text cố định: *"Tôi bị sốt cao đau đầu và mệt mỏi từ hôm qua"*.

- OCR fail silently khi không có EasyOCR.
- Lab Sanity Checker hoạt động tốt với 9 ngưỡng sinh lý.

Module D: RAG Knowledge (70%)

Sub-module	Hoàn thiện
RAG Knowledge Store (40KB JSON)	72%
Vector Store (TF-IDF cosine)	75%
RAG Service wrapper	60%
Kaggle 41 Diseases Dataset	78%
Vietnamese Medical QA Corpus	65%

- Vector embedding dùng **TF-IDF** thay Dense Embeddings (BGE-M3) ⇒ chất lượng semantic search thấp.
- Qdrant đã config trong `config.py` nhưng **chưa tích hợp** vào RAG pipeline.
- Knowledge base hạn chế (41 bệnh), chưa phủ đủ phác đồ BYT Việt Nam.

Module E: Gemini LLM (78%)

Sub-module	Hoàn thiện
Gemini Service (REST urllib)	82%
Clinical Reasoning Fallback	78%
Local LLM (Ollama-compat)	65%
Vietnamese System Prompt	85%

- Model hiện dùng `gemini-1.5-flash` ⇒ nên nâng cấp lên `gemini-2.0-flash`.
- Không có **retry logic** khi Gemini API timeout / rate-limit.
- Context window chỉ lấy **6 turn cuối** ⇒ thiếu context với hội thoại dài.
- Vietnamese system prompt chất lượng cao: **85%** hoàn thiện.

Module F: Backend API Layer (73%)

Endpoint	%	Ghi chú
Chat API (REST + SSE + WS)	82%	**OK**
Admin API	75%	**OK**
Auth API (JWT)	55%	**plain-text!**
Medical Records API	70%	**OK**
Upload API	60%	file validation thiếu
WebSocket streaming	78%	typewriter effect

- **SECURITY BUG**: Auth API lưu password **plain-text** trong DB — cần bcrypt ngay.
- Chat Service (`chat_service.py`): **628 dòng**, logic phong phú, xử lý nhiều edge case tốt.

Module G: Database & Persistence (22% — CRITICAL)

Component	%	Trạng thái
MongoDB Motor	20%	**In-Memory**
In-Memory DB	55%	mất khi restart
Redis Cache	10%	**Thiếu hoàn toàn**
Qdrant Vector DB	15%	**Thiếu hoàn toàn**
Session Storage	30%	RAM only
File Storage (MinIO)	40%	local disk

RỦI RO CAO NHẤT: Toàn bộ dữ liệu (users, sessions, messages, records) **mất khi restart server**.

- Hệ thống **không thể Production-ready** ở trạng thái này.

7. Luong Du Lieu Thuc Te (8 Buoc)

Bước	Module	Xử lý	Output
[1]	Intent Guard	Phân loại: chào hỏi / ngoài y tế / y tế	Route decision
[2]	AI Pipeline	Audio $\rightarrow$ STT; Image/PDF $\rightarrow$ OCR; Text pass-through	Unified text + lab dict
[3]	Medical NER	Rule-based regex $\rightarrow$ Synonym normalize $\rightarrow$ Negation detect $\rightarrow$ Red Flag	symptoms, negated, is_emergency
[4]	Hybrid Predict	NLP branch (TF-IDF + SVC) + Tabular branch (XGBoost) + Fusion α-blend	Top 3–5 ICD-10 + confidence
[5]	RAG Retrieval	TF-IDF cosine similarity 300+ docs + ICD-10 boost	Top 3 clinical guidelines
[6]	Gemini LLM	Build prompt (symptoms + predictions + RAG + history) $\rightarrow$ gemini-1.5-flash	Clinical response text
[7]	Clarification	Shannon Entropy $> \theta \rightarrow$ generate follow-up questions	Clarification payload
[8]	SSE Stream	Token-by-token typewriter streaming về Frontend	JSON chunks

- **Lưu ý thực tế**: Bước [2] STT trả về simulated text nếu faster-whisper chưa cài; Bước [3] NER dùng rule-based nếu PhoBERT weights thiếu.
- Bước [5] RAG dùng TF-IDF (chưa phải Qdrant Dense Embedding) $\Rightarrow$ kết quả semantic search chưa đạt tối ưu.

8. Ket Qua Hieu Nang Dinh Luong

Hiệu năng các thành phần AI (thực tế)

Component	Hoàn thiện	Latency
NLP Classifier (TF-IDF + SVC)	85%	< 50ms
TF-IDF Vectorizer (fitted)	90%	< 20ms
XGBoost Tabular	80%	< 30ms
Hybrid Predictor (Fusion)	82%	< 80ms
Clarification Engine	88%	< 30ms
RedFlagDetector	85%	< 15ms
RAG (TF-IDF cosine)	75%	< 100ms
Gemini API call	78%	500–1500ms
End-to-end (text only)	—	~700ms

Các chỉ số mô hình đang chạy

Chỉ số	Giá trị
ICD-10 classes active	32–41 lớp
Knowledge base	41 bệnh (Kaggle)
Negation patterns	9 patterns
Red flag patterns	FAST, MI, Dengue
Chat context window	6 turns cuối
Simulated STT (fallback)	Cố định 1 câu

Điểm nổi bật & Giới hạn

- Chat Service logic **628 dòng** — xử lý edge case tốt nhất trong hệ thống.
- Vietnamese System Prompt Gemini: **85%** — chất lượng cao.
- Hệ thống **chưa có benchmark** F1 chính thức do thiếu test dataset chuẩn hóa.

9. Technical Debt — Danh sach Uu tien

CRITICAL — Chặn Production

#	Vấn đề	Vị trí	Ảnh hưởng
TD-01	MongoDB không persistent	database.py	Mất toàn bộ dữ liệu khi restart
TD-02	Password plain-text	auth.py	Lỗ hổng bảo mật nghiêm trọng
TD-03	faster-whisper chưa cài	whisper_model.py	STT trả về text cố định
TD-04	PhoBERT weights thiếu	phobert_ner/	NER chạy rule-based thay Deep Learning
TD-05	Redis chưa implement	redis.py	Không có caching, hiệu năng thấp

HIGH — Ảnh hưởng chất lượng AI

#	Vấn đề	Giải pháp đề xuất
TD-06	sentence-transformers chưa cài	pip install + Qdrant integration
TD-07	Qdrant chưa tích hợp RAG	Kích hoạt từ docker-compose
TD-08	Chỉ 41 bệnh, cần 200+	Retrain XGBoost + mở rộng ICD-10
TD-09	Gemini 1.5 Flash (cũ)	Nâng cấp gemini-2.0-flash
TD-10	Không có retry logic Gemini	Exponential backoff + circuit breaker

10. Lo Trinh Phat Trien — 3 Giai Doan

Phase 1: Stabilize

Tuần 1–6 | Mục tiêu: 80%

- Kích hoạt MongoDB Atlas (free tier) → Motor async CRUD.
- bcrypt hash passwords (passlib có sẵn).
- `pip install faster-whisper sentence-transformers`
- Tải PhoBERT NER weights (VinAI).
- Kích hoạt Redis caching (session + triage).
- Đưa `SECRET_KEY` ra `.env`.

Phase 2: Expand AI

Tuần 7–14 | Mục tiêu: 90%

- Qdrant Dense Embedding (multilingual-MiniLM).
- Fine-tune PhoBERT NER trên Vietnamese Medical corpus.
- Nâng cấp Gemini → gemini-2.0-flash + retry + streaming.
- Mở rộng ICD-10: 41 → 200+ bệnh phổ biến VN.
- Retrain NLP Classifier + XGBoost.
- Tăng context window Gemini lên 20 turns.

Phase 3: Microservices

Tuần 15–28 | Mục tiêu: 96%

- Tách microservice: Chat / AI Engine / OCR / Admin.
- Message Queue: Redis/Celery cho OCR + Training tasks.
- Triton Inference Server (NLP + XGBoost).
- LoRA fine-tune LLaMA/Mistral trên dữ liệu y tế VN.
- FHIR R4 Export + HL7 integration.
- Mobile App (React Native).

11. Diem Manh Hien Tai & Tinh Nang Nang Cap Uu Tien

5 Điểm mạnh hiện tại

- **Kiến trúc AI đa tầng** ấn tượng: NLP + Tabular + Fusion + RAG + Gemini LLM.
- **Chat Service** (628 dòng): xử lý tốt nhiều edge case, Intent Guard, Negation.
- **UI/UX Frontend**: Real-time SSE streaming, Admin Panel hiện đại.
- **Training Pipeline**: skeleton đầy đủ, kết nối Google Co-lab.
- **Vietnamese System Prompt**: chất lượng cao 85%, reasoning y tế tốt.

Hành động ngay (tuần này)

- `pip install faster-whisper sentence-transformers`
- MongoDB Atlas free tier → set `MONGODB_URL` trong `.env`
- Sửa `database.py`: hash password bằng bcrypt

Tính năng AI High-Value (ưu tiên cao)

Tính năng	Ưu tiên
Longitudinal Patient Memory (MongoDB)	P0
Lab Report Auto-analysis (toàn bộ chỉ số)	P1
Multi-disease Session Detection	P1
Drug Interaction Checker	P1
Audit Log AI Reasoning Chain	P1
Real-time Doctor Collaboration	P1
Vital Signs Trending	P2
FHIR R4 Export	P2
Fine-tuned Medical LLM (LoRA)	P3
Federated Learning	P3

SAMSUNG

Together for Tomorrow!

Enabling People

Education for Future Generations

© 2023 SAMSUNG. All rights reserved. Samsung Electronics Corporate Citizenship Office holds the copyright of this document. Reprint and reproduction without permission are prohibited.