SAMSUNG

MediBot AI — Trợ lý Y tế Đa Phương Thức Thông Minh

Hệ thống Sàng lọc Phân tầng Lâm sàng, Trích xuất Triệu chứng & Tra cứu Phác đồ Bộ Y Tế

Samsung Innovation Campus — Capstone Project Presentation

Nhóm SIC-UTT · Nguyễn Bá Duy (Trưởng nhóm) · Trương Tuấn Vũ · Nguyễn Trần Hiệp · Đặng Thị Thúy Linh

Phiên bản hệ thống: Phase 2 Production Beta | Kết quả đo kiểm thực nghiệm 100% trên Codebase

Together for Tomorrow!

Enabling People

Education for Future Generations

Nội Dung Trình Bày

1. Đặt Vấn Đề & Mục Tiêu
- Thực trạng quá tải y tế & Giải pháp tiếp cận

2. Kiến Trúc Hệ Sinh Thái
- Monorepo: Frontend + FastAPI + AI Engine

3. CSDL Tri Thức & Phác Đồ BYT
- 1.407 mã ICD-10 & 427 phác đồ chính quy

4. PhoBERT Medical NER
- Transformer Token Classification (199 tensors)

5. Phân Loại Lâm Sàng Hybrid
- NLP Classifier + Tabular XGBoost (211 lớp)

6. Late Fusion & Cờ Đỏ Cấp Cứu
- Độ trễ ≤ 50ms, cảnh báo FAST, STEMI, Sốc

7. Shannon Entropy & Làm Rõ
- Thu hẹp chẩn đoán với thông tin bất định

8. RAG Dense Vector Database
- 1.840 tài liệu lâm sàng, 384-dim embeddings

9. Mô Hình Gemini 2.0 Flash
- Multi-turn context 20 lượt, SSE typewriter

10. Xử Lý Xét Nghiệm & Sinh Lý
- Lab Sanity Checker, hiệu chỉnh OCR tự động

11. Đánh Giá Hiệu Năng
- Top-1 90.67%, Top-3 96.00% (150 ca holdout)

12. Phân Tích Độ Trễ Hệ Thống
- Breakdown từng chặng: Phản hồi < 1.2 giây

13. Scorecard Hoàn Thiện (90%)
- Đánh giá 9 modules đạt chuẩn Production Beta

14. Kết Luận & Định Hướng
- Đóng góp thực tiễn và lộ trình mở rộng

1. Đặt Vấn Đề & Mục Tiêu Đề Tài

Thực trạng & Thách thức Tiếp nhận Y tế

- **Quá tải nghiêm trọng**: Các bệnh viện tuyến trung ương luôn trong tình trạng quá tải phòng khám tiếp đón ban đầu.
- **Mô tả triệu chứng mơ hồ**: Người dân dùng khẩu ngữ đời thường, tiếng lóng, khó mô tả chính xác bệnh cảnh.
- **Đọc sai kết quả xét nghiệm**: Bệnh nhân không tự hiểu các chỉ số công thức máu (CBC), sinh hóa máu cơ bản.
- **Bỏ sót thời gian vàng cấp cứu**: Thiếu công cụ phát hiện tức thì đột quỵ (FAST), nhồi máu cơ tim, sốc sốt xuất huyết.

Mục tiêu Giải pháp MediBot AI

- **Sàng lọc phân tầng tự động**: Kết hợp dữ liệu văn bản, giọng nói (STT) và ảnh/PDF phiếu xét nghiệm (OCR).
- **Phân loại trên 211 nhóm bệnh lý**: Dự đoán Top-1 và Top-3 mã bệnh ICD-10 độ chính xác cao ($> 90\%$).
- **Cảnh báo khẩn cấp tức thời**: Cổng Red Flag xử lý trong ≤ 50 ms, kích hoạt hotline 115 và chỉ dẫn sơ cứu.
- **Tham chiếu phác đồ chính thống**: RAG truy xuất từ 427 phác đồ Bộ Y Tế, chống ảo giác y khoa (Hallucination).
- **Tư vấn tự nhiên qua LLM**: Tích hợp Gemini 2.0 Flash với trí nhớ hội thoại 20 lượt đối thoại.

2. Kiến Trúc Hệ Sinh Thái Đa Phương Thức

Cấu trúc 3 Phân hệ Kiến trúc (Monorepo)

- **Next.js 14**: Giao diện streaming SSE typewriter, upload phiếu xét nghiệm, STT audio visualizer, admin panel.
- **FastAPI Backend**: Chat Service (628 dòng), quản lý session, JWT an toàn, cổng kết nối WebSocket/SSE.
- **Core AI Engine**: Điều phối PhoBERT NER, XGBoost, Dense RAG, Shannon Entropy & Gemini 2.0 Flash.

Khả năng Dự phòng Cao (High Resilience)

- Qdrant DB tự động failover sang In-Memory Dense Matrix.
- Gemini 2.0 Flash tự động fallback Rule-based Clinical Engine.

Luồng Xử Lý 4 Tầng Pipeline

- **Tầng 1 — Tiếp Nhận & Tiền Xử Lý**: Phân loại Intent Guard, chuyển giọng nói Whisper STT, bóc tách ảnh/PDF xét nghiệm qua OCR.
- **Tầng 2 — Trích Xuất Thực Thể & Cờ Đỏ**: PhoBERT NER gán nhãn BIO triệu chứng, bộ lọc Red Flag quét cấp cứu khẩn trong ≤ 50 ms.
- **Tầng 3 — Phân Loại & Hòa Trộn Late Fusion**: Kết hợp NLP Classifier và Tabular XGBoost trên 211 nhóm bệnh, đo Shannon Entropy.
- **Tầng 4 — Tham Chiếu Tri Thức & Suy Luận**: RAG Dense Vector truy xuất 427 phác đồ BYT, Gemini 2.0 Flash trả lời qua SSE stream.

3. CSDL Tri Thức Y Khoa & Phác Đồ Bộ Y Tế

Cơ Sở Dữ Liệu Bệnh Lý ICD-10 Chuẩn Hóa

► **1.407 mã bệnh ICD-10**: Biên dịch và chuẩn hóa tiếng Việt đầy đủ từ 22 chương bệnh của Bộ Y Tế (`chuong1` đến `chuong22`).

► **211 nhóm bệnh lý trọng điểm**: Không gian bệnh lý tích cực (Active Classes) được đánh chỉ mục trong `disease_classes_index.json`, bao phủ hầu hết các ca ngoại trú thường gặp.

► Mỗi thực thể bệnh bao gồm: tên chuẩn tiếng Việt, tên tiếng Anh, triệu chứng điển hình (cardinal), triệu chứng kèm theo, dặn dò phòng ngừa và dấu hiệu cấp cứu.

Kho Phác Đồ Điều Trị Bộ Y Tế

► **427 văn bản phác đồ chính thức** (`rag_knowledge_store.json`): Hướng dẫn chẩn đoán và điều trị chính quy (QĐ 2760/QĐ-BYT sốt xuất huyết, phác đồ hen, đái tháo đường, tim mạch,...).

Từ Điển Triệu Chứng & Chuẩn Hóa Ngữ Nghĩa

Tài nguyên CSDL	Quy mô	Đặc tính kỹ th
`icd10_codes.json`	1.407 mã	22 chương BY
`disease_classes_index`	211 lớp	Active classifie
`symptom_synonyms.json`	461 KB	1.030 gốc, 4.25
`rag_knowledge_store`	427 tài liệu	Phác đồ điều tr
TF-IDF Char N-Gram	33.484 features	Chuẩn hóa 14.
QA Corpus Y Khoa	6 corpus lớn	Tư vấn ngoại t

► Ánh xạ đa dạng khẩu ngữ địa phương: ví dụ *"nổi mề đay"*, *"nổi mẩn ngứa"*, *"phát ban đỏ"* → chuẩn hóa về thực thể duy nhất: **Dị ứng da / Mày đay**.

4. PhoBERT Medical NER (Deep Learning Transformer)

Kiến Trúc Mô Hình & Bộ Trọng Số

- Xây dựng trên nền tảng **vinai/phobert-base-v2** fine-tuned chuyên biệt cho thực thể lâm sàng tiếng Việt.
- Bộ weights nạp trực tiếp gồm **199 tensors** (`model.safetensors`, `config.json`, `vocab.txt`, `bpe.codes`) tại thư mục `models_weights/phobert_ner/`.
- **Tập dữ liệu huấn luyện**: 50.000 mẫu câu lâm sàng gán nhãn BIO (`phobert_synthetic_ner.json`) mô phỏng câu nói tự nhiên của bệnh nhân.
- Cơ chế Self-Attention nắm bắt mối tương quan xa trong câu dài, loại bỏ phụ thuộc vào từ điển từ khóa thô sơ.

Khả Năng Trích Xuất Đa Thực Thể

- **Triệu chứng (SYMPTOM)**: Sốt cao, đau đầu dữ dội, tức ngực...
- **Dấu hiệu sinh tồn**: Thân nhiệt (39°C), thời gian khởi phát.

Thuật Toán Xử Lý Ngữ Cảnh Phủ Định (Negation)

- Áp dụng thuật toán **Window Negation Boundary** (cửa sổ 45 ký tự trước thực thể kết hợp dấu ngắt câu và liên từ).
- Bộ 9 biểu thức quy tắc y khoa nghiêm ngặt nhận diện câu phủ định: *"không bị", "chưa từng", "hết hẳn", "hoàn toàn không thấy", "âm tính với"...*
- Phân loại rạch ròi 2 tập: `extracted_symptoms` và `negated_symptoms` để ngăn chặn chẩn đoán sai lệch.

Ví dụ thực tế trích xuất:
*"Tôi sốt 39 độ, đau đầu nhưng **không** buồn nôn hay chảy máu chân răng."*
⇒ **Triệu chứng khẳng định**: Sốt cao, Đau đầu
⇒ **Triệu chứng phủ định**: Buồn nôn, Chảy máu chân răng

5. Mô Hình Phân Loại Lâm Sàng Hybrid

Kết hợp Calibrated NLP Semantic Classifier và Tabular

Nhánh 1: NLP Semantic Classifier

- Chuyển đổi văn bản triệu chứng thành ma trận đặc trưng qua **TF-IDF Vectorizer** (ngram 1–3, tối đa 12.000 features, sublinear TF).
- Bộ phân loại **CalibratedClassifierCV** (Logistic Regression $C = 5.0$, 3-fold cross validation) hiệu chuẩn xác suất chuẩn xác.
- Không gian đầu ra: Phân loại trực tiếp **211 nhóm bệnh lý ICD-10** với xác suất $P_{\text{text}}(c)$.

Nhánh 2: Tabular XGBoost Classifier

- Huấn luyện trên **23 đặc trưng lâm sàng**: 9 chỉ số sinh hóa máu (WBC, PLT, RBC, HGB, HCT, AST, ALT, GLUCOSE, CREATININE) và 14 cờ triệu chứng nhị phân lâm sàng.
- Cấu hình tối ưu: 180 cây quyết định (`n_estimators=180`), `max_depth=6`, `learning_rate=0.08`, hàm mục tiêu `multi:softprob` trên 211 classes.

Hiệu Suất Huấn Luyện Các Mô Hình

Mô hình	Kích thước	Độ chính xác Train/Va
NLP Symptom Classifier	10.5 MB	**91.4%** (Val Accuracy
TF-IDF Vectorizer	518 KB	12.000 features n-gra
Tabular XGBoost	1.54 MB	**92.8%** (Val Accuracy
Label Index Mapping	41 KB	211 classes activ

Ưu Thế Của Mô Hình Đa Nhánh

- Khi bệnh nhân chỉ nhập triệu chứng bằng lời: Nhánh NLP gánh trọng trách phân loại chính.
- Khi có kết quả xét nghiệm máu: Nhánh Tabular phát huy sức mạnh phân biệt vượt trội (ví dụ Dengue tụt PLT sâu < 100, viêm gan men gan AST/ALT tăng vọt).

6. Late Fusion & Cổng Lọc Cờ Đỏ Cấp Cứu

Cơ Chế Hòa Trộn Xác Suất Late Fusion

- Xác suất tổng hợp cuối cùng được tính theo công thức hàm trọng số thích ứng:

$$P_{\text{final}}(c) = \alpha \cdot P_{\text{tabular}}(c) + (1 - \alpha) \cdot P_{\text{text}}(c)$$

- **Trọng số động** α:
  - $\alpha = 0.65$: Khi có kết quả xét nghiệm máu (ưu tiên chỉ số định lượng khách quan).
  - $\alpha = 0.00$: Khi chỉ có lời khai triệu chứng từ bệnh nhân.
- **Penalization Phủ định**: Các bệnh xuất hiện trong tập triệu chứng phủ định bị phạt trừ xác suất tự động.

Cổng Lọc Cờ Đỏ Cấp Cứu (Red Flag Rapid Filter)

- Chạy song song ở tầng đầu vào với **độ trễ siêu tốc** ≤ 50 **ms**.
- **FAST Protocol (Đột quỵ não)**: Méo miệng, lệch mặt, yếu liệt nửa người, nói ngọng $\rightarrow$ kích hoạt cảnh báo đột quỵ khẩn.
- **STEMI/NSTEMI (Nhồi máu cơ tim)**: Đau ngực đè ép dữ dội lan tay trái/hàm, vã mồ hôi, khó thở hoặc Troponin tăng.
- **Dengue Shock**: Xuất huyết chân răng/chảy máu cam + sốt cao kéo dài + tiểu cầu hạ cấp tính (< 50 G/L).
- **Hành động can thiệp**: Hiển thị khung báo động đỏ, nút gọi cấp cứu 115 một chạm và cẩm nang sơ cứu tại chỗ.

Định Lượng Độ Bất Định Lâm Sàng

- Khi bệnh nhân cung cấp thông tin chung chung (*"thấy mệt mỏi, khó chịu"*), xác suất dự đoán bị phân tán đều trên nhiều bệnh.
- Hệ thống tính toán **Độ hỗn loạn thông tin Shannon (Shannon Entropy)** trên Top-K phân phối xác suất dự đoán:

$$H(P) = -\sum_{i=1}^{K} p_i \log_2(p_i)$$

- **Điều kiện kích hoạt Clarification Loop**:
  - $H(P) > \theta = 1.8$ nats (độ hỗn loạn vượt ngưỡng an toàn).
  - Hoặc khoảng cách xác suất Top-1 và Top-2: $\Delta p = p_{(1)} - p_{(2)} < 0.15$.

Cơ Chế Sinh Câu Hỏi Phân Biệt

- Tự động tra cứu ngân hàng câu hỏi lâm sàng theo cặp bệnh cần phân biệt (Differential Diagnosis).
- Lựa chọn 2–3 câu hỏi có **Information Gain** cao nhất về triệu chứng khu biệt quan trọng.
- Sau phản hồi, cập nhật xác suất Bayes, thu hẹp không gian chẩn đoán nhanh chóng.

Tình huống thực tế (Case 005):
Input: *"Tôi thấy trong người hơi mệt mỏi, khó chịu"*
$\Rightarrow$ Entropy $H = 2.31 > 1.8 \rightarrow$ Kích hoạt làm rõ:
1. Bạn có bị sốt hoặc gai rét không?
2. Triệu chứng này đã kéo dài bao nhiêu ngày?
3. Bạn có kèm theo ho, khó thở hay đau tức ngực không?

8. Hệ Thống RAG Dense Vector Database

Kiến Trúc Dense Retrieval Chuyên Sâu

► Không sử dụng từ khóa so khớp thô (BM25/TF-IDF đơn thuần), hệ thống sử dụng **Dense Semantic Embeddings 384 chiều** chuyển đổi toàn bộ phác đồ y khoa thành các vector tri thức.

► **Quy mô tri thức nạp vào DB**: **1.840 tài liệu lâm sàng** bao gồm:

- 427 phác đồ chẩn đoán và điều trị chính thức của Bộ Y Tế.
- 1.407 hồ sơ chi tiết mã bệnh ICD-10.
- 6 bộ hồ sơ ca bệnh tư vấn lâm sàng ngoại trú thực tế.

► **Cơ chế Resilient In-Memory Failover**: Nếu dịch vụ Qdrant Vector DB gặp sự cố, hệ thống tự động kích hoạt ma trận NumPy Cosine Similarity nội tại với độ trễ < 45 ms, tính sẵn sàng đạt 100%.

Thuật Toán Truy Vấn Lai (Hybrid Retrieval)

► Kết hợp Cosine Vector Similarity với mã bệnh dự đoán từ phân loại học sâu để tăng trọng số phác đồ chính xác.

► Trích xuất Top-3 tài liệu phác đồ có điểm tin cậy cao nhất gắn kèm trích dẫn pháp lý và y văn chính quy.

Thực Nghiệm Truy Vấn (Query Benchmark)

Tài liệu phác đồ truy xuất	Mã	Điểm số
Hướng dẫn Chẩn đoán & Lâm sàng SXH Dengue	A90	**0.9049**
Phác đồ Dược Lâm sàng & Xử trí Dengue	A90	**0.7665**
Phác đồ BYT điều trị SXH người lớn (QĐ 2760)	A90	**0.6911**

► Triệt tiêu hiện tượng ảo giác (Hallucination) của LLM bằng việc ép buộc căn cứ vào văn bản phác đồ thực tế.

9. Mô Hình Suy Luận Lâm Sàng Gemini 2.0 Flash

Tích Hợp Mô Hình Gemini 2.0 Flash

► Ứng dụng mô hình suy luận đa phương thức mới nhất **gemini-2.0-flash** từ Google DeepMind.

► **System Prompt Y tế Tiếng Việt Chuyên Biệt**: Được tinh chỉnh theo chuẩn mực giao tiếp bác sĩ — bệnh nhân: giải thích cặn kẽ, thái độ ân cần, khuyến cáo rõ ràng không tự ý dùng kháng sinh.

► **Multi-turn Context Memory 20 lượt**: Cửa sổ trượt lưu giữ 20 lượt đối thoại gần nhất (40 tin nhắn), nắm trọn tiền sử bệnh, dị ứng thuốc và diễn tiến triệu chứng trong suốt phiên tư vấn.

Trải Nghiệm Thời Gian Thực (SSE Streaming)

► Kỹ thuật truyền luồng Server-Sent Events (SSE) theo cơ chế gõ chữ (Typewriter), giảm thời gian chờ đợi của người dùng.

Kiến Trúc Dự Phòng An Toàn 3 Tầng (3-Tier Fall-back)

Tầng 1 (Primary): Gemini 2.0 Flash API
→ Suy luận sâu, giải thích phác đồ, trả về SSE stream.

Tầng 2 (Local Fallback): Clinical Reasoning Service
→ Rule-based engine cục bộ ghép phác đồ Bộ Y Tế thành văn bản tư vấn có cấu trúc khi mất kết nối Internet.

Tầng 3 (Safety Guard): Emergency Safety Template
→ Mẫu phản hồi an toàn y khoa tuyệt đối khi phát hiện cờ đỏ cấp cứu hoặc lỗi hệ thống không xác định.

► Đảm bảo dịch vụ tư vấn y tế **hoạt động liên tục 24/7** không bao giờ bị sập hay mất kết nối hoàn toàn.

Quy Trình Tiếp Nhận Đa Phương Thức

- **Định dạng hỗ trợ**: Tệp PDF bệnh án (PyMuPDF) hoặc ảnh chụp phiếu xét nghiệm (EasyOCR / Tesseract).
- **Dynamic Regex Parser**: Bóc tách tên chỉ số, giá trị số thực và đơn vị đo chuẩn y tế (10^9/L, g/dL, μmol/L).

Thuật Toán Lab Sanity Checker

- **Tự động sửa lỗi quang học (OCR)**: Phát hiện nhầm lẫn dấu chấm thập phân. Ví dụ: nhận diện WBC 320.0 tự động điều chỉnh về **3.2** (10^9/L) phù hợp sinh lý.
- **Kiểm định 9 chỉ số cơ bản**: WBC (Bạch cầu), PLT (Tiểu cầu), RBC (Hồng cầu), HGB (Hemoglobin), HCT, AST, ALT (Men gan), Glucose (Đường huyết), Creatinine (Chức năng thận) và Troponin I/T.

Phân Tầng Cảnh Báo Ngưỡng Sinh Tồn

Chỉ số	Giá trị	Trạng thái	Hành động
WBC	3.2 10^9/L	LOW	Cảnh báo suy giảm miễn d
PLT	45 10^9/L	**CRIT_LOW**	Báo động xuất huyết nguy
ALT	420 U/L	HIGH	Cảnh báo hủy hoại tế bào
Troponin	50 ng/L	**CRIT_HIGH**	Kích hoạt cấp cứu nhồi ma

Đóng Góp Vào Late Fusion

- Các chỉ số sau kiểm định được đưa vào nhánh Tabular XGBoost để tăng vọt độ tin cậy của chẩn đoán (ví dụ PLT < 50 làm tăng xác suất Sốt xuất huyết Dengue từ 35% lên 92%).

11. Đánh Giá Hiệu Năng Thực Nghiệm & Độ Trễ

Độ Chính Xác Phân Loại (150 Ca Holdout Set)

Tiêu chí Đánh giá	Số lượng / Tỷ lệ	Đánh giá
Tổng số ca bệnh kiểm định	150 ca lâm sàng	Độc lập
Độ chính xác Top-1	**136 / 150 (90.67%)**	**ĐẠT** Xuất sắc
Độ chính xác Top-3	**144 / 150 (96.00%)**	**ĐẠT** Rất cao
Sai số phân loại Top-1	14 / 150 (9.33%)	Ca triệu chứng mờ nhạt
Benchmark E2E (8 ca test)	8 / 8 (100.0%)	**ĐẠT** Đạt 100%
Tỷ lệ kích hoạt Entropy	100% ca mơ hồ	**ĐẠT** Hoàn hảo

► Các ca sai số Top-1 chủ yếu là ca có duy nhất 1 triệu chứng mơ hồ như *"mệt mỏi dài ngày"* (khó phân biệt giữa Viêm gan B mạn và Suy giáp nếu chưa có xét nghiệm).

Bảng Phân Tích Độ Trễ Toàn Hệ Thống (Latency)

Thành phần thực thi	Thời gian đáp ứng
Cổng lọc Cờ đỏ Cấp cứu (Red Flag)	< **50 ms**
PhoBERT Medical NER	85 – 140 ms
Tabular XGBoost (211 lớp)	15 – 30 ms
Nhật Semantic Classifier (211 lớp)	35 – 60 ms
RAG Dense Vector Search (1.840 docs)	< **45 ms**
Gemini 2.0 Flash (Time-to-First-Token)	450 – 650 ms
Tổng phản hồi đầu tiên tới User	< **1.2 giây**

► Tốc độ phản hồi đạt chuẩn tương tác trực tuyến thời gian thực, không gây cảm giác nghẽn mạng cho người dùng.

14. Scorecard Hoàn Thiện & Kết Luận Đề Tài

Scorecard 9 Phân Hệ (Phase 2 Production)

Phân hệ Chức năng	Tiến độ	Đánh giá
A. AI Engine / NLP (211 lớp)	92%	ĐẠT
B. PhoBERT Medical NER (Deep Learning)	88%	ĐẠT
C. STT + OCR & Lab Sanity Checker	82%	ĐẠT
D. RAG Vector DB (427 Phác đồ BYT)	88%	ĐẠT
E. Gemini 2.0 Flash (Context 20 turns)	94%	ĐẠT
F. Backend API (FastAPI Async + SSE)	88%	ĐẠT
G. Database & Memory Architecture	80%	ĐẠT
H. Training Pipeline & Colab Scripts	90%	ĐẠT
I. Frontend Next.js 14 UI/UX	92%	ĐẠT
TỔNG THỂ HỆ THỐNG (Production Beta)	**90%**	**90%**

Đóng Góp Nổi Bật & Định Hướng

- **Ứng dụng AI chuẩn mực**: Sàng lọc phân tầng đa phương thức tiếng Việt.
- **An toàn y khoa hàng đầu**: Cờ đỏ cấp cứu < 50ms, 427 phác đồ BYT.
- **Sản phẩm hoàn chỉnh**: Trọn vẹn từ mô hình học sâu tới Next.js 14.
- **Định hướng**: Mở rộng app di động React Native & chuẩn FHIR R4.